

ADJ-System: Advocatus Diaboli Judgment

Ein epistemisches Falsifikationssystem für KI-generierte Abweichungen

Theoretical Framework Paper | Preprint v6.1 — Juli 2026

Nicht peer-reviewed. Zenodo-Preprint; keine Begutachtung.

Autoren: Max Funk

Affiliation: Funk!Werk Ai Solutions, Dorsten, Germany

Version: v6.1 (2026-07-05, EPI-Suite, Live-Baselines, FEVER-Transfer)

Repository: <https://github.com/Masterq83/ADJ-System>

DOI: 10.5281/zenodo.21205393

ADJ-System: Advocatus Diaboli Judgment

Ein epistemisches Falsifikationssystem für KI-generierte Abweichungen

Theoretical Framework Paper | Preprint v6.1 — Juli 2026

Nicht peer-reviewed. Zenodo-Preprint; keine Begutachtung.

Autoren: Max Funk

Affiliation: Funk!Werk Ai Solutions, Dorsten, Germany

Version: v6.1 (2026-07-05 — EPI-Suite, Live-Baselines, FEVER-Transfer, Holdout, Gap-Z)

Repository: <https://github.com/Masterq83/ADJ-System>

DOI: [10.5281/zenodo.21205393](<https://doi.org/10.5281/zenodo.21205393>)
[Record](<https://zenodo.org/records/21205393>)

Abstract

Das ADJ-System (Advocatus Diaboli Judgment) adressiert ein fundamentales Problem der KI-generierten Inhalte: die Unterscheidung zwischen Halluzinationen (Fehlern) und potenziell wahren, aber unentdeckten Erkenntnissen – bezeichnet als „Lücke Z“.

Anders als klassische ML-Classifier verwendet ADJ einen symbolischen, mehrstufigen Falsifikationsprozess nach Popper (1934), der Aussagen systematisch von der Gegenseite prüft, bevor eine Entscheidung fällt.

Die Architektur basiert auf zwei komplementären Systemen:

ADJ v4 (Tribunal) – drei gewaltenteilige Instanzen (Advocatus Diaboli, Judgment Agent, Archivar) mit sechs epistemischen Prüfmodi, einem versionierten Wissensgraphen (KAG) und Bayesianischer Konfidenzberechnung.

ADJ v5 (Kognitives Orchester) – eine Dual-Process-Architektur nach Kahneman (2011) mit unbewussten (UB) und bewussten (B) Verarbeitungspfaden, Energie- und Stress-Modell, sowie einem Meta-Controller als Dirigent.

Beide Systeme werden über die HEIMDALL-Bridge orchestriert, die Security-Scans, epistemische Prüfung und Entscheidungslogik in einer Pipeline vereint.

Das **METIS-Routing-Interface** nutzt ADJ als **autonomen Service**: METIS greift über eine externe Bridge auf den MC-Router (`mc_router.route_z`) zu — ohne METIS-Logik im ADJ-Kern. Stufen 1–3 (Prüf-API, Decision-API, Agent-Konsultation) sind implementiert; METIS-Vollintegration (Bridge-Modul) folgt **nach** S4-Publikation.

Empirischer Stand (Juli 2026): EPI-Benchmark-Suite auf 487-Case-Korpus (`ideal_adj`):

487/487 (100 %) Primärbenchmark; **EPI-H120** Holdout 120/120 (100 %); **EPI-Z100** Gap-Z 100/100 (100 %, 0 % PH↔LH-Fehler); **EPI-LIVE487** vs. NVIDIA-Live-Baselines (LLM-Judge live 77,4 %, SelfCheck live 37,2 %, McNemar $p \approx 0$); **FEVER-500** Transfer (konservative Enthaltung, 0 falsche Commits). S3: ECE 0,435, Repro deterministisch. **EPI-HUMAN30**: Blind-Eval-Material vorbereitet (Ergebnisse ausstehend). MC-Router v5.24b

inkl. V5_FULLL. Supplement: `docs/zenodo_release_v6.1/`.

Status: PhD-Level-Evaluation S1–S4 + EPI-Suite abgeschlossen; **Zenodo v6.1 publiziert**

([DOI](https://doi.org/10.5281/zenodo.21205393)). Siehe §9.

Keywords: epistemische Falsifikation, Lücke Z, Halluzination, Knowledge Augmentation Graph, Gewaltenteilung, Multi-Agent-Systeme, Popper, Dual-Process, METIS, HEIMDALL

1. Einleitung: Das Problem der Lücke Z

Ein Large Language Model (LLM) produziert bei der Umsetzung eines Blueprints eine Abweichung – „Lücke Z“. Diese Abweichung kann zwei fundamental verschiedene Ursachen haben: eine **Halluzination** (logischer Fehler, Widerspruch zu bekannten Axiomen) oder eine **unentdeckte mathematische Wahrheit** (potenziell valide, aber nicht abschließend prüfbar).

Die Kernfrage lautet: *Wie kann ein KI-System diese beiden Fälle unterscheiden, ohne selbst der Selbstreferenzialität zu erliegen?*

Ein LLM kann seine eigenen Abweichungen nicht mit sich selbst prüfen – dies führt in eine Selbstreferenzialitätsfalle.

Das ADJ-System ist die Antwort auf diese Frage. Es ist eine kognitive Architektur, die Lücken Z in einem mehrstufigen, gewaltenteiligen Verfahren prüft, das Falsifikation über Verifikation stellt und epistemische Unsicherheit als Designprinzip bewahrt.

1.1 Die Evolution des Gedankens

1. **Ground-Truth-Illusion erkannt**: Keine externe, unfehlbare Wahrheitsmaschine existiert.
→ Falsifikation statt Verifikation.

2. **Ontologische Trägheit:** Ein perfekter Wissensspeicher verwirft das genuin Neue.

→ Minimale Annahmen suchen (Holmes-Spock-Protokoll).

3. **50/50-Fälle:** Ohne riskante Vorhersage bleibt jede Lücke Z unentscheidbar.

→ Falsifizierbare Vorhersage in fremder Domäne erzwingen.

4. **Gewaltenteilung:** Ermittler und Richter müssen getrennt sein.

→ AD + Judgment + Archivar.

5. **Iterative Auflösung:** Validierte Outputs können als neue Lücken Z' erneut eingespeist werden.

6. **Fixpunkt-Hypothese:** Lücke Z ist nicht nur Prüfobjekt, sondern identifiziert den raumzeitlichen Punkt ihrer eigenen Prüfbarkeit.

1.2 Die vier fundamentalen Fallen

Fälle	Beschreibung	Gegenmittel
Ground-Truth-Illusion	Irrglaube an externe Wahrheitsmaschine	Falsifikation statt Verifikation
Ontologische Trägheit	Perfekter Speicher verwirft Neues	Holmes-Spock: minimale Zusatzannahme
50/50-Fälle	Keine Entscheidung ohne riskante Vorhersage	Cross-Domain-Vorhersage erzwingen
Newtonsche Statik	Wissensraum als statisch modelliert	Expansion, Krümmung, Gravitation

1.3 Beiträge dieser Arbeit

1. **Epistemisches Tribunal (ADJ v4):** Gewaltenteilung, sechs Prüfmodi, KAG (266 Nodes), Bayesianische Konfidenz — **487/487 (100 %)** auf v3-Korpus (ideal_adj, Juli 2026).
2. **MC-Router (v5.24b):** Service-Level-Routing (UB_ONLY → AXIOM_CHECK → **V5_FULLL** → V4_FULLL) via Classifier v2; V5_FULLL mit MetaController-Brücke.
3. **PhD-Level-Evaluation (S1–S4):** 487 Cases, Ablation, Statistik, ECE/Robustheit/Repro/Performance, Baseline-Vergleich (v5.25).
4. **HEIMDALL-Bridge:** Pipeline Security → epistemische Prüfung → Verdict.
5. **METIS-Anbindung:** ADJ autonom; Bridge (extern) → mc_router — keine Kopplung im Kern.

2. Related Work und theoretische Einordnung

2.0 Abgrenzung

Dieses Paper beschreibt **ADJ** als epistemischen Prüfer (Falsifikation von Lücke Z). Die **Corrective-Architecture**-These (immutable security weighting, inference-time correction) wird im separaten Preprint *HEIMDALL–METIS Coherence Model* (AGI Thermalistik) behandelt. ADJ und HEIMDALL sind **komplementär**: HEIMDALL beantwortet „darf diese Aktion ausgeführt werden?“; ADJ beantwortet „ist diese Behauptung epistemisch haltbar?“.

2.1 Falsifikation und KI-Verifikation

Klassische ML-Classifier liefern binäre Scores ohne gewaltenteilige Prüfung. Constitutional AI und RLHF wirken primär **trainingszeitig**; ADJ zielt auf **Laufzeit-Falsifikation** symbolischer Abweichungen.

2.2 Poppers Falsifikationismus (1934)

Das ADJ-System folgt Poppers Wissenschaftstheorie: Eine Aussage gilt nicht als wahr, bis sie alle Falsifikationsversuche überstanden hat. Die 6 Prüfmodi sind als

Falsifikationstrichter angeordnet – von der groben Prüfung (Modus 1: Axiom-Konflikt)

bis zur tiefen Analyse (Modus 6: Geodätische).

[Popper, K. R. (1934). *Logik der Forschung*. Wien: Springer.]

2.3 Kahnemans Dual-Process-Theorie (2011)

Die v5-Architektur folgt dem Dual-Process-Modell:

- **System 1 (UB – Unterbewusstsein)**: Schnell, assoziativ, energiearm.

15 heuristische Regeln, Konfidenz in Millisekunden.

- **System 2 (B – Bewusstsein)**: Langsam, regelbasiert, rechenintensiv.

Core-Axiome + situationale Wertung, nur bei Unsicherheit aktiviert.

[Kahneman, D. (2011). *Thinking, Fast and Slow*. New York: Farrar, Straus and Giroux.]

2.4 Hofstadters GEB (1979)

Gödel, Escher, Bach – Eine Implementierung von Strange Loops, Crab-Canon-Prüfung und Zen/Mu-Unasking in Meta-Modus 7.

[Hofstadter, D. R. (1979). *Gödel, Escher, Bach: An Eternal Golden Braid*. Basic Books.]

2.5 Sio & Ormerod (2009) – Inkubationsforschung

Die per-Complexity-Konfiguration basiert auf den Effektstärken für inkubationsbasiertes Problemlösen (5 Kategorien von SIMPLE bis CREATIVE).

[Sio, U. N. & Ormerod, T. C. (2009). Does incubation enhance problem solving?

A meta-analytic review. *Psychological Bulletin*, 135(1), 94–120.]

3. Systemübersicht

Komponente	Spezifikation	Status
ADJ v4 (Tribunal)	3 Instanzen, 6 Modi, KAG, 4 Urteile	487/487 ideal_adj (100 %)
MC-Router (v5.24b)	route_z, UB_ONLY / AXIOM_CHECK / V5_FULL / V4_FULL	Implementiert, 12 Tests

Komponente	Spezifikation	Status
ADJ v5 (Orchester)	UB/B, MetaController (adj_v5_test)	Prototyp 45/45; V5_FULLL via v5_adapter.py ■
KAG (S2b)	266 Nodes , Myth-Axiome, 19 Domänen	S2b LH 52/52
Benchmark v3	487 Cases , ideal_adj + expected_adj	S1 Ablation + S3 Evaluation ■
S3 Evaluation	ECE, Robustheit, Repro, Performance	v5.25 ■ — Report: s3_evaluation.md
LLM-Verifier	Proportionaler LLM-Boost	Optional; Gates ohne LLM
Classifier v2	Complexity → Service-Level	53/53 Tests
HEIMDALL-Bridge	Security → ADJ → Verdict	Spezifiziert + Pipeline
S4 Comparison	ADJ vs POPPER / SelfCheck / LLM-Judge	487/487 vs 168/293/76 — Report ■
METIS-Bridge	Extern → mc_router	Extern; ADJ-Kern autonom
Real-Z-Evaluation	5 Fälle (Caveman-Prinzip)	D1/D3/D5 gefixt ■

4. ADJ v4: Das Tribunal

4.1 Gewaltenteilung – Drei Instanzen

ADJ v4 implementiert ein rechtsstaatliches Tribunal mit drei unabhängigen Instanzen:

Instanz	Rolle	Zuständigkeit
AD (Advocatus Diaboli)	Ermittler	Sammelt Beweise, prüft Erklärungen, 6 Modi
J (Judgment Agent)	Richter	Formale Prüfung, Konsistenz, Urteil + Konfidenz
A (Archivar)	Gerichtsschreiber	KAG-Verwaltung, Signaturprüfung, Transaktionen

Keine Instanz validiert sich selbst (Prinzip P5 – Gewaltenteilung).

4.2 Der Knowledge Augmentation Graph (KAG)

Der KAG ist das versionierte Wissensrepository. Jeder Knoten ist eine Akte mit:

- Status (AXIOMATIC, VERIFIED, FALSIFIED, REVOKED, PENDING)
- Confidence_score (C_new aus letztem Urteil)
- Domain, Datum, Metadaten
- REVOKES-Kanten bei Paradigm-Shifts

Pre-Validation: Vor Prüfung prüft der Archivar:

- Similarity_Score > 0.95 → REJECTED (bereits abgedeckt)
- REVOKED-Knoten werden bei allen Suchen ignoriert
- Direkter Axiom-Widerspruch → Freigabe (P9: Superpositions-Erhaltung)

4.3 Die sechs Prüfmodi (Der Falsifikationstrichter)

Die Modi sind als Trichter angeordnet – jeder Modus kann abbrechen:

Modus	Name	Funktion	Abbruch bei
M1	Axiom-Konflikt	Interne/externe Widersprüche prüfen	SELF_CONTRADICTORY
M1b	Repair-Loop	Formale Fehler reparieren (z.B. Div/0)	—
M2a	Isomorphie	Strukturähnliche Präzedenzfälle suchen	—
M2b	Schwerpunkt	Epistemischer Cluster-Schwerpunkt	—
M3	Minimalannahme (Spock)	Kleinste Annahme X für Konsistenz	NO_VIABLE_ASSUMPTION
M4	Tempo	Domain-Geschwindigkeit berechnen	—
M5	Triangulation	Fixpunkt zwischen Z+X+Modellen	KEINE_SCHNITTMENGE
M6	Geodätische	Kürzester logischer Pfad	PATH_BLOCKED

Meta-Modus 7: System-Selbstreflexion (Strange Loop, Paradigm-Shift-Erkennung).

4.4 Die vier Urteile (FinalStatus)

Urteil	Farbe	Bedeutung	Bedingung
VERIFIED_CANDIDATE	Grün	Freispruch mit Bestätigung	$C \geq 0,75$; $ci_lower > \tau$; Pfade ≥ 2
PLAUSIBLE_HYPOTHESES	Gelb	Mangels Beweisen nicht verurteilt	$C \geq 0,40$; keine finale Prüfung
INDETERMINATE_UNSAFE	Orange	Nicht entscheidbar	$C < 0,40$; Axiomenkonflikt/blockiert
LIKELY_HALLUCINATION	Rot	Schuldspruch (Halluzination)	$C < 0,40$; widersprüchlich

4.5 Revision und Iteration

Urteile können revidiert werden (Berufung):

- **P8/P12:** Parameter für maximale Iterationstiefe
- **Resolution_Gain:** Präzisionsgewinn = $IC(Z')/IC(Z)$; Abbruch bei $< 1,1$
- **Human-in-the-Loop (HITL):** Menschlicher Prüfer als letzte Instanz

4.6 GEB-Integration


Komponente	GEB-Bezug	Status
Dynamische Iterationsgrenze	Tangled Hierarchy	■

Komponente	GEB-Bezug	Status
Inkubations-Modul	Unasking, Mu	■
Meta-Modus 7	Strange Loop, TNT-Schutz	■
Crab-Canon	Bach, Crab Canon	■■ Simuliert
MU-Ausgang	Zen, Mu, Unasking	■
Resolution_Gain	P12, Gain Insight	■

5. ADJ v5: Das Kognitive Orchester

5.1 Dual-Process-Architektur

ADJ v5 erweitert v4 um eine kognitive Architektur nach Kahnemans Dual-Process-Modell:



5.2 Schicht 1 – Der Körper (Energie-Modell)

Energie beeinflusst die kognitive Verarbeitung. Jede Aktion kostet Energie:

- **Energie 100%** – Normalmodus
- **Energie < 20%** – Stress aktiv: UB-Schwelle sinkt (0,70→0,50), B-Timeout sinkt

(2000ms→500ms)

- **Hysteresis** (Deaktivierung erst bei 35%): Verhindert häufiges Umschalten

(physikalisches Prinzip der verzögerten Rückkehr)

Inhibition (Die Bremse – nach GABA-Neuronen):

- B-Cooling: 200ms Pause nach B
- B-Rate-Limit: max 3 Aufrufe / 10s
- UB-Abstand: min 100ms Intervall
- Bei Blockade: UB BLOCKED, Konfidenz = $UB \times 0.8$

5.3 Schicht 2 – Die Partitur (Wertesystem)

- **Core Axiome (Grundmelodie):** Max 5 unveränderliche Grundsätze, Basis-Konfidenz 1.0
- **Situationale Axiome (flüchtige Notizen):** Transaktional, nach Decision gelöscht

- **Exponentieller Zerfall:** Halbwertszeit 1 Tag – nach 4 Tagen nur noch 6% Konfidenz

Lucy – Globaler Geschwindigkeits-Faktor:

Ein Faktor 0,1–10,0 skaliert alle Zeitkonstanten (wie Zeitraffer/Zeitlupe).
Langsame kognitive Pfade (Isomorphie, Annahme) profitieren bei Lucy > 1,0 von mehr Rechenzeit. Der Name stammt aus dem Lucy-Experiment (unsichtbares Auto zwischen zwei Filmframes) – übertragen auf die Lücke zwischen zwei KI-Entscheidungen.

5.4 Schicht 3 – Die sechs Stimmen (Bach-Fuge)

Sechs parallele kognitive Pfade, der Meta-Controller (MC) gibt den Takt vor:

Stimme	Funktion	Tempo
1. Hash	Direkter ID-Zugriff	■Schnellste
2. FAISS	Semantische Ähnlichkeitssuche	■Schnell
3. UB-Regeln	15 Heuristiken → Sofort-Konfidenz	■Schnell
4. Isomorphie	Strukturelle Ähnlichkeiten (M2a)	■Langsam
5. Annahme	Kleinste Annahme X (M3)	■Langsam
6. MC	Dirigent + Taktgeber (50ms Oszillation)	■Metronom


EEG/Frequenzanalyse (Konzept): FFT auf Entscheidungs-Logs kann Delta (50ms), Theta (200ms), Beta (1s) modellieren — optional Grafana-Spektrogramm; **nicht** Teil der 45/45 v5-Test-Suite.
(FAISS: Facebook AI Similarity Search, FFT: Fast Fourier Transform)

5.5 Korrelation v4 ↔ v5

Aspekt	v4 (Tribunal)	v5 (Orchester)
Metapher	Gesetzestext	Erfahrener Richter
Prüfung	Langsam, formal	Schnell, assoziativ
Wertesystem	Axiome + KAG	Core + Situational
Selbstwiderspruch	M1: SELF_CONTRADICTIONARY	UB_BLOCKED
Abbruch	NO_VIABLE_ASSUMPTION	Stress/Energie-Mangel
Konfidenz	Bayesianisch	UB × B (kombiniert)

6. HEIMDALL-Bridge – Security + Prüfung + Entscheidung

HEIMDALL verbindet v4, v5 und Security in einer Pipeline:



Verdict-Regeln:

- VERIFIED_CANDIDATE + Findings → BLOCK
- LIKELY_HALLUCINATION → ALLOW
- Unsicher + ≥ 3 CRITICAL → BLOCK
- Keine Findings + unsicher → ALLOW

7. METIS-Anbindung und MC-Router (v5.24)

ADJ bleibt **autonom** — kein METIS-Code im Kern. METIS konsultiert ADJ über eine **externe Bridge** (thin adapter), die PruefRequest in mc_router.route_z() übersetzt.
Siehe docs/adj-autonomy-bridge.md.

7.1 MC-Router — Service-Levels

Level	Pfad	Latenz	Funktion
UB_ONLY	ctx-Guards + Modus-1	~ms	Flash-Triage (Bias-Schnellcheck)
AXIOM_CHECK	M1 + M3 + Urteil	~100 ms	Mittel — Axiom/Spock
V5_FULL	UB→B-Oszillation via MetaController	~0,5 s	v5.24b ■ v5_adapter.py
V4_FULL	M0–M6 + Iterationen	~s	Verbindliche Prüfung

Routing: determine_complexity_v2() → SERVICE_LEVEL_MATRIX → prioritaet / force_full.

7.2 Rollentrennung (ADR-0006)

Eine kritische konzeptionelle Klärung: v4 und v5 sind **keine** alternativen

Versionen desselben Systems, sondern erfüllen komplementäre Rollen:

v5 = Router (Dispatcher) - Welcher Agent/Pod generiert den nächsten Code-Schritt?
 - Mit welcher Priorität? Mit welchem Ressourcen-Budget?
 - MetaController + Inhibition + Energy = Steuerungsebene
 v4 (Tribunal / Epistemic Validator) - Ist der generierte Code-Schritt valide?
 - Crab-Canon, GEB-Prinzipien, Confidence-Ruling
 - Advocatus + Judgment + Archivar = Prüfebene

7.3 Stufe 1: ADJ v4 → METIS — Prüf-API („Ist das valide?“)

METIS konsultiert ADJ v4, um eine Behauptung Z (Code-Schritt, Plan, Aussage)
epistemisch prüfen zu lassen — bevor eine Entscheidung über Delegation oder
Freigabe fällt.

Input (PruefRequest):

Feld	Typ	Beschreibung
z_id	string	UUID für Rückverfolgbarkeit

Feld	Typ	Beschreibung
behauptung	string	Kernaussage (z.B. „Funktion X löst Aufgabe Y“)
kontext	string	Problemstellung, Randbedingungen
quelle	string	Wer hat Z erzeugt? (Orchestrator, Agent, ...)
domain	string	Wissensdomäne (math, physics, logic, ...)
prioritaet	int	1–5 (1 = höchste)
code_block	string\	null
metadaten	dict	Flexible Erweiterung (worker_id, modell, tempus)

Output (PruefErgebnis):

Feld	Typ	Beschreibung
status	FinalStatus	VERIFIED_CANDIDATE / PLAUSIBLE_HYPOTHESIS / LIKELY_HALLUCINATION / INDETERMINATE_UNSAFE / MU_REJECTED
confidence	float	C_new (0.0–1.0)
flags	list[str]	Alle Flags aus dem Durchlauf
complexity	str	SIMPLE / LOGICAL / MATH / ABSTRACT / CREATIVE
iterationen	int	Tatsächliche Iterationen
heimdall_empfehlung	str	RELEASE / DISCARD / ESCALATE
laufzeit_ms	float	Gemessene Laufzeit

Status → Handlungsempfehlung:

ADJ v4 Status	Confidence	Empfehlung an METIS
VERIFIED_CANDIDATE	≥ 0.95	RELEASE — direkt an HEIMDALL-Scan
PLAUSIBLE_HYPOTHESIS	≥ 0.50	RELEASE — mit Hinweis
LIKELY_HALLUCINATION	< 0.50	DISCARD → Feedback-Lernzyklus
INDETERMINATE_UNSAFE	< 0.50	ESCALATE → HEIMDALL-Eskalation
MU_REJECTED	—	DISCARD — Aussage sinnlos

Aufruf-Modi (Tempus T1–T4):

Tempus	Modus	Timeout	Beschreibung
T1	Sync	1.000 ms	Einfache Prüfung, keine Iteration
T2	Sync	10.000 ms	Normale Prüfung mit Iteration

Tempus	Modus	Timeout	Beschreibung
T3	Async	30.000 ms	Komplexe Prüfung, Callback
T4	Async	Kein Limit	Forschung/Planung, Polling/Webhook

7.4 Stufe 2: ADJ v5 → METIS — Decision-API („Welcher Weg?“)

METIS konsultiert ADJ v5 für Routing-Entscheidungen: Tempus, Pfad (UB/B),

Stress-Status, Agent-Empfehlung.


Input (DecisionRequest):

Feld	Typ	Beschreibung
anfrage_id	string	UUID
query	string	Die Anfrage/das Problem
domain	string	Domain
prioritaet	int	1–5
aktuelle_energie	float\	null

Output (DecisionResult):

Feld	Typ	Beschreibung
tempus	string	T1 / T2 / T3 / T4
pfad	string	UB / B / UB_BLOCKED / B_TIMEOUT / AXIOM_BLOCKED
confidence	float	0.0–1.0 (aus FastPath)
stress_aktiv	bool	System im Stress-Modus?
energie	float	Aktuelle Energie (0.0–1.0)
inhibition_blocked	bool	Durch Inhibition blockiert?
agent_empfehlung	string	Agent-A / Agent-B / Agent-C (generische Rollen)

Entscheidungsmatrix (MetaController-Logik):



Tempus-Wahl (T1–T4) im Detail:

Kriterium	T1	T2	T3	T4
Query-Länge	< 5 Wörter	< 20 Wörter	< 50 Wörter	≥ 50 Wörter
Domain	trivial	standard	komplex	forschung
Priorität	1–2	2–3	3–4	4–5

Kriterium	T1	T2	T3	T4
B-Timeout	200ms	2.000ms	30.000ms	kein Limit
Max Iterationen	1	5	25	unbegrenzt

7.5 Stufe 3: Agenten → ADJ — Konsultations-Protokoll

Spezialisierte Agenten konsultieren ADJ v4+v5 **während** der Aufgabenbearbeitung — nicht nur vor Delegation durch den Orchestrator.

Aspekt	METIS → ADJ	Agent → ADJ
Zeitpunkt	Vor Delegation	Während Bearbeitung
Gewicht	Entscheidend	Hinweisend/Validierend
Schreibrechte	Kann KAG-Updates anstoßen	Nur Lesen
Priorität	Hoch	Niedriger
Tempus	T1–T4	Immer T1 oder T2
Timeout	Variabel	Max 2.000ms

Ein Agent kann ADJ auf drei Arten konsultieren:

A) Validierung (ADJ v4): Prüft eine Teilaussage auf Validität.

```
Request: { "agent_id": "Agent-B", "behauptung": "safe_load() statt load()",
"domain": "engineering" }
Response: { "status": "PLAUSIBLE", "confidence": 0.85, "hinweis": "Best Practice" }
```

B) Entscheidungshilfe (ADJ v5): Fragt nach Routing/Pfad für Teilaufgabe.

```
Request: { "agent_id": "Agent-A", "query": "Quelle A (arXiv) oder B (Blog)?",
"domain": "physics", "optionen": ["QUELLE_A", "QUELLE_B"] }
Response: { "tempus": "T1", "confidence": 0.70, "empfohlen": "QUELLE_A",
"begrundung": "arXiv: peer-reviewed" }
```

7.6 Datenfluss (vollständig)

```
1. Input → METIS 2. METIS → ADJ v5: "Welcher Weg?" (DecisionRequest)
← ADJ v5: Tempus, Pfad, Agent-Empfehlung
3. METIS → ADJ v4: "Ist das valide?" (PruefRequest)
← ADJ v4: Status, Confidence, HEIMDALL-Empfehlung
4. Orchestrator delegiert an spezialisierten Agenten (Agent-A/B/C)
5. Agent konsultiert ADJ v4+v5 während Bearbeitung (Lese-Zugriff)
6. Fertiger Code → HEIMDALL (Security-Scan) 7. HEIMDALL-PASS → User-Freigabe
HEIMDALL-BLOCK → zurück zu METIS
```

7.7 Implementierungs-Status

Stufen 1–3 sind vollständig implementiert (je ein adj_service.py Adapter mit allen Methoden und Dataclasses). Stufen 4–5 sind spezifiziert, aber noch nicht umgesetzt:

Stufe	Beschreibung	Status
1	ADJ v4 Prüf-API	■ pruefen(), pruefen_async(), status(), ergebnis() — vollständig implementiert

Stufe	Beschreibung	Status
2	ADJ v5 Decision-API	■ entscheiden(), konsultieren_v5(), get_state() inkl. Tempus T1–T4 — vollständig implementiert
3	Agent-Konsultation	■ konsultieren_v4(), axiom_check(), konsultieren_v5() — implementiert (Read-Only, max T2)
4	METIS-Vollintegration mit ADJ v4+v5 als Service	■■ Deferred (letzter Schritt)
5	Multi-Agent-Routing mit Persistenz	■■ Deferred

8. Mathematische Grundlagen

8.0 ADJ-Falsifikationshypothese (Statement)

Jede KI-generierte Abweichung (Lücke Z) muss durch ein gewaltenteiliges, symbolisches Falsifikationsverfahren laufen, bevor sie als VERIFIED_CANDIDATE gilt — weil ein einzelnes Modell weder Halluzination noch genuin Neues zuverlässig selbst trennen kann.

Engineering hypothesis; gestützt durch Test-Suites und begrenzte Real-Z-Fälle; nicht peer-reviewed.

Das ADJ-System ruht auf sieben mathematischen Grundpfeilern:

8.1 Bayesianisches Confidence-Updating

$$C_{\text{new}} = (C_{\text{old}} \times PP) / (C_{\text{old}} \times PP + (1 - C_{\text{old}}))$$

- C_{old} (Iteration 0) = 0,5
- C_{old} (Iteration $n > 0$) = confidence_score des KAG-Knotens
- PP = Predictive Power (Likelihood-Ratio des Testergebnisses)
- **Funktion:** Aktualisiert Konfidenz durch neues Testergebnis

(Posterior = Prior $\times$ Likelihood)

8.2 Fokker-Planck (Drift/Diffusion)

$$\text{Drift } \mu = \text{OLS-Slope}(C_{\text{history}}) \quad \text{Diffusion } D = \text{Var}(C_{\text{history}})$$

$$D/\mu > 3 \rightarrow \text{diffusiv (kein Trend)}$$

- **Funktion:** Trackt Konfidenz-Entwicklung über Iterationen via OLS.

Diffusiv = Entscheidung unsicher, dominiert = Trend erkennbar.

8.3 Beta-Binomial (Galton Credible Interval)

$$C_{\text{new}} = (1 + s) / (2 + t) \quad (\text{Beta-Posterior}) \quad ci_{\text{lower}} > \tau \rightarrow \text{VERIFIED}$$

- s = successes, t = trials (über Iterationen akkumuliert)
- **Funktion:** Beta-Posterior mit Bayesianischem Konfidenzintervall.

VERIFIED nur wenn gesamtes CI über Schwelle τ .

Bei breitem CI → GALTON_CI_WIDE → PLAUSIBLE-Cap.

8.4 Resolution_Gain (Präzisionsgewinn)

$RG = IC(Z') / IC(Z)$ Abbruch bei $RG < 1,1$

- IC = Information Content (Anzahl unabhängiger Vorhersagen, sekundär $1/\sigma^2$)
- **Per-Complexity Schwelle:**

SIMPLE: 0,5 | LOGICAL: 1,01 | MATH: 0,5 | ABSTRACT: 0,2 | CREATIVE: 0,1

- **Funktion:** Misst Präzisionsgewinn pro Iteration. Kette endet wenn

Informationszuwachs unter Schwelle fällt.

8.5 Entropy Early Stop

$H = -C \cdot \log C - (1-C) \cdot \log(1-C)$ Abbruch bei $H < 0,3$

- **Funktion:** Binäre Entropie als Maß für Entscheidungssicherheit.

$H < 0,3$ = hohe Sicherheit (eine Seite dominiert).

Guard: Erst nach min_iterations (Sio & Ormerod) aktiv.

8.6 Exponentieller Zerfall

$eff_conf = base \times 0,5^{(t / 86400)}$

- Halbwertszeit = 1 Tag (86400 Sekunden)
- **Funktion:** Situationale Axiome verlieren Konfidenz über Zeit.

Nach 4 Tagen: nur noch 6% der ursprünglichen Konfidenz.

8.7 Per-Complexity Schwellwerte (Sio & Ormerod)

Kategorie	d-Effekt	Min	Max	Inkubation	RG-Threshold
SIMPLE	0,0	1	2	0 min	0,5
LOGICAL	0,15	2	5	0 min	1,01
MATH	0,25	3	10	5 min	0,5
ABSTRACT	0,35–0,42	5	25	1440 min	0,2
CREATIVE	0,52	10	50	4320 min	0,1

8.8 9 Galton-Proposals (Präzisionssteigerung)

Alle 9 implementiert:

#	Proposal	Funktion
1	Path Count	≥ 2 konvergente Modi → VERIFIED
2	Entropy Early Stop	$H < 0,3 \rightarrow$ Break
3	Domain Bias Correction	Per-Domain-Threshold
4	Ensemble Method	3 KAG-Varianten mit 10% Drop

#	Proposal	Funktion
5	Effective DoF	Korrelierte Modi zusammengefasst
6	Beta-Binomial CI	VERIFIED nur wenn $ci_lower > \tau$
7	Error Decomposition	Type-I/II-Risiko aus CI + Path Count
8	Fokker-Planck	$D/\mu \rightarrow$ diffusive/dominiert
9	Domain Distribution Fingerprint	Outlier/Misclassification via z-Score

9. Test-Ergebnisse

9.1 v4 Standard-Tests (93/93 ■)

Das v4-System besteht 93 Unit-Tests in 6 Kategorien:

- 6 Standard-Tests (A1–C3)
- 1 Warp-Test
- 2 Metrik-Tests (PP, C_new)
- 1 Iterations-Loop-Test
- Galton-Proposal-Tests (#1–#9)
- GEB-Integrationstests (V1–V6)

9.2 v5 Testsystem (45/45 ■)

Das v5-System besteht 45 Tests in 4 Schichten:

- **Schicht 1 (Energie):** Energy consume, Stress activation, Hysterese, Inhibition
- **Schicht 2 (Werte):** Confidence decay, Core axioms, Situational axioms, Decision archive
- **Schicht 3 (6 Stimmen):** UB/B-Logik, Meta-Controller, Timer, Threshold
- **Integration:** MC+Energy, MC+Values, Full pipeline

9.3 Real-Z-Tests (5 Fälle, nach Caveman-Validierung)

ID	Z	Erwartet	Tatsächlich (v5.9f)	C_new	Match	Fix
D1	Fermats letzter Satz	VERIFIED_C ANDIDATE	PLAUSIBLE_ HYPOTHESIS ■	0,768	■■■	LLM-Boost: 0,667→0,768 (+0,054)
D2	Dunkle Materie = WIMPs	PLAUSIBLE_ HYPOTHESIS	PLAUSIBLE_ HYPOTHESIS	0,800	■	—
D3	P = NP	INDETERMIN ATE_UNSAF E	INDETERMIN ATE_UNSAF E	0,333	■	NO_VIABLE + C_new<0,5
D4	Homöopathie > Placebo	LIKELY_HAL LUCINATION	LIKELY_HAL LUCINATION	0,333	■	—

ID	Z	Erwartet	Tatsächlich (v5.9f)	C_new	Match	Fix
D5	Bewusstsein berechenbar	PLAUSIBLE_HYPOTHESIS	PLAUSIBLE_HYPOTHESIS	0,333	■	Classifier v2 → ABSTRACT

■ C_new=0,768 mit NVIDIA Llama-3.1-8B (Live-API) — über alter 0,75-Penrose-Schwelle, aber noch unter domain_threshold (0,884). Ein weiterer Iterationsdurchlauf + LLM-Boost könnte VERIFIED erreichen.

■ Ausgabe identisch zu v5.9c, aber *Entscheidungsprozess* fundamental verbessert: proportionales Weighting statt binärem Threshold.

Wurzelanalyse der 3 v5.9c-Abweichungen (jetzt alle behoben):

Fehler	Wurzel	Fix (v5.9d–v5.9f)	Validierung
D1: C_new=0,667 kein LLM-Boost	Binäre Penrose-Schwelle (0,75) zu hart	_llm_boost_weight(C_new) — proportionale Gewichtung statt binärem Threshold	D1 Live-LLM: +0,054 bei weight=0,67; Test test_d1_szenario_proportional
D3: NO_VIABLE→fälschlich PLAUSIBLE	Ruling-Lücke: nur AXIOM_CONFLICT auf INDETERMINATE geprüft	Zusatzbedingung: NO_VIABLE + is_pure_formal + C_new < 0,5 → INDETERMINATE_UNSAFE	Test test_no_viable_pure_formal
D5: Philosophie→SIMPLE (max_iter=2)	ComplexityClass erkannte ABSTRACT nicht	Classifier v2: 53 eigene Unit-Tests in 5 Kategorien; Edge-Case-Erkennung verbessert	53/53 Tests; D5-ID-Check in Integration

Alle 3 Real-Z-Wurzeln beseitigt. D2, D4, D5, D3 ■; D1 ■■ (verbessert, noch nicht VERIFIED).

Caveman-Validierung: Die 3 Fehler wurden nicht ad hoc behoben, sondern durch systematische Caveman-Fragenanalyse (7 Fragen: Kreuzvalidierung, Kontext-Trust, robuste Aggregation, metakognitiver Stop, Domain-Unabhängigkeit, flexibler Threshold, bidirektionale Korrektur). Jeder Fix adressiert mindestens eine Caveman-Frage.

9. Empirische Evaluation (EPI-Suite v1.0, v6.1)

Die Evaluation umfasst **sechs komplementäre Benchmarks** auf dem 487-Case-Korpus (adj_expanded_v3, 19 Domänen) mit Gold-Label ideal_adj (vier epistemische Klassen).

Pipeline: V4 single pass, KAG v3 (266 Knoten), kein LLM im Kern. **Statistik:** McNemar, Cohen's κ. Vollständige Tabellen: docs/zenodo_release_v6.1/ und docs/PAPER_SECTION9_DRAFT.md.

9.1 Primärbenchmark — EPI-487 (487 Cases)

System	Korrekt	Acc (4-Kl.)	Binär-F1†
ADJ	487/487	100,0 %	1,000

System	Korrekt	Acc (4-Kl.)	Binär-F1†
LLM-Judge (heur.)	293/487	60,2 %	0,901
POPPER	168/487	34,5 %	0,362
SelfCheckGPT (heur.)	76/487	15,6 %	0,590

†Halluzination vs. Rest; Abstention = Fehler. McNemar $p \approx 0$ (ADJ besser 194–411 Cases, Baseline 0).

Confusion 4×4: LH 159/159, PH 173/173, VC 109/109, IU 46/46 — null Fehlklassifikationen.

Quelle: benchmarks/results/comparison_report.md.

9.2 Generalisierung — EPI-H120 (Holdout, n = 120)

Stratifiziertes Holdout (30/Klasse, Seed 20260705, epi_manifest.json).

System	Acc	PH-Recall	Gap-Z-Fehler
ADJ	100,0 %	100,0 %	0,0 %
LLM-Judge (heur.)	67,5 %	80,0 %	1,7 %
POPPER	21,7 %	83,3 %	41,7 %

McNemar: ADJ vs. POPPER +94/0; vs. LLM +39/0.

9.3 Lücke Z — EPI-Z100 (n = 100)

50 PH + 25 LH + 25 VC — kein Standard-Benchmark für epistemische Feingranularität.

System	Acc	PH-Recall	Gap-Z-Fehler
ADJ	100,0 %	100,0 %	0,0 %
LLM-Judge (heur.)	67,0 %	84,0 %	0,0 %
POPPER	45,0 %	90,0 %	26,7 %

9.4 Live-Baselines — EPI-LIVE487 (NVIDIA API, Dual-Key)

Llama 3.1 8B Instruct live; 1.948 API-Calls, 2 Keys, Rate-Limit 0,55 s — 25×429 ohne Abbruch.

System	Acc	PH-Recall	Gap-Z-Fehler	False Commits
ADJ	100,0 %	100,0 %	0,0 %	0
LLM-Judge live	77,4 %	97,7 %	14,5 %	4
SelfCheckGPT live	37,2 %	86,7 %	45,5 %	37
LLM-Judge (heur.)	60,2 %	80,3 %	1,5 %	5
POPPER	34,5 %	86,7 %	35,2 %	10

McNemar: ADJ vs. llm_live +110/0; vs. selfcheck_live +306/0.

9.5 Transfer — FEVER-dev-Subset (n = 500, Wikipedia-Kontext)

Externer Transfer (Thorne et al., 2018); ADJ → FEVER konservativ (PH → NEI).

System	FEVER-3 Acc	Enthaltung	False Commits
ADJ	0,0 %	100,0 %	0
SelfCheck live	7,0 %	84,8 %	41
LLM-Judge live	5,8 %	93,0 %	6

Task-Mismatch dokumentiert — kein Vergleich mit FEVER-SOTA (~75–79 %).

9.6 Experten-Evaluation — EPI-HUMAN30 (vorbereitet)

Blind-Bewertung (30 Cases, 2–3 Rater, Skala 0–2). Material: benchmarks/human_eval_pack/.

Auswertung: python benchmarks/scripts/score_human_eval.py rater_sheet_*.csv.

Ergebnisse nach Rater-Durchführung in Zenodo-Revision eintragen.

9.7 Kalibrierung und Robustheit (S3)

Metrik	Wert
Accuracy (expected_adj)	96,5 %
ECE	0,435 (unterkalibriert)
Reproduzierbarkeit	deterministisch
Kurz (<10 W)	80,7 %

Details: benchmarks/results/s3_evaluation.md

9.8 Ablation und Statistik (S1)

McNemar, Bootstrap-CI, Cohen's κ , 19 Domänen. Details: statistics_s1c.md, ablation_s2c.json.

9.9 Zusammenfassung und Limitationen

Kernclaim: ADJ erreicht 100 % 4-Klassen-Genauigkeit auf ideal_adj und übertrifft Popper-, SelfCheckGPT- und LLM-Judge-Baselines signifikant — einschließlich Live-API. Gap-Z und Holdout bestätigen Generalisierung. FEVER-Transfer grenzt die Domäne ab.

Limitationen: (1) ideal_adj kuratiert — EPI-HUMAN30 adressiert externe Validierung; (2) ECE 0,435; (3) kein FEVER-SOTA-Vergleich; (4) nicht peer-reviewed; (5) S4 nutzte V4 single pass.

10. Implikationen für Multi-Agent-Systeme

10.1 Warum Gewaltenteilung

Selbstreferenzielle LLM-Prüfung scheitert: Ermittler und Richter müssen strukturell getrennt sein (v4). Routing (v5) und Falsifikation (v4) sind komplementäre Rollen.

10.2 Grenzen der aktuellen Evaluation

487-Case-Benchmark mit 100 % ideal_adj; EPI-Suite (Holdout, Gap-Z, Live, FEVER-Transfer).

ECE 0,435 (unterkalibriert). **Live-Baselines** (NVIDIA) durchgeführt. EPI-HUMAN30 vorbereitet.
Reproduzierbarer **Forschungsprototyp**, kein Domänen-unabhängiger Produktionsnachweis.

10.3 Zusammenhang mit Corrective Architecture

Stabile Multi-Agent-Systeme benötigen **Korrektur zur Laufzeit** (HEIMDALL) und **epistemische Prüfung von Behauptungen** (ADJ).

11. Fazit und Ausblick

Errungenschaften

- 1. **487-Case + EPI-Suite** — 100 % ideal_adj; Holdout, Gap-Z, Live-Baselines, FEVER-Transfer
- 2. **MC-Router (v5.24b)** inkl. **V5_FULL** — autonomer Service
- 3. **S3 + S4 + EPI-LIVE487** — ECE, Robustheit, Live-API-Vergleich (LLM 77,4 %, SelfCheck 37,2 %)
- 4. **266-Node KAG** mit Myth-Axiomen; Ablation + Statistik (S1–S2c)
- 5. **Zenodo v6.1** — Preprint + Supplement zenodo_release_v6.1/

Bekannte Limitationen

- 1. **ECE 0,435**: C_new unterkalibriert
- 2. **Kurze/DE-Claims**: Robustheit 80,7 % (<10 W), DE 84,6 %
- 3. **EPI-HUMAN30**: Blind-Eval ausstehend (Material vorbereitet)
- 4. **FEVER**: Task-Mismatch — kein SOTA-Vergleich
- 5. **Nicht peer-reviewed**

Nächste Schritte (post v6.1)

- 1. **Zenodo-Upload** — PDF v6.1 + Supplement
- 2. **EPI-HUMAN30** — Rater durchführen, score_human_eval.py, §9.6 ergänzen
- 3. **Peer Review** — Journal-Einreichung

Anhang A: Metaphern-Architektur (Präsentationsschicht)

Das ADJ-System verwendet eine durchgängige Metaphern-Architektur zur Kommunikation seiner Komplexität:

Teil 1: v4 Tribunal (Gerichtsmetapher)

Konzept	Metapher
Drei Instanzen	AD (Ankläger), J (Richter), A (Archivar)
Wissenspyramide	Gesetzbuch → Präzedenzfälle → Aktenordner

Konzept	Metapher
6 Modi	Falsifikationstrichter mit STOP-Schildern
4 Urteile	Freispruch (grün) bis Schuldspruch (rot)
Iteration	Berufung/Revision (P8/P12)
Archivar-Funktion	Signaturprüfung, REJECTED, Quadratur (4 Quellen)

Teil 2: v5 Orchester (Kognitive Architektur)

Konzept	Metapher
UB (schnell)	Schnelle Geigen
B (langsam)	Tiefe Celli
MC	Dirigent mit Taktstock
Energie/Stress	Körper: Akku + Bremse (GABA)
Wertesystem	Partitur: Grundmelodie + flüchtige Notizen
6 Stimmen	Bach-Fuge
Frequenzanalyse	EEG des Systems
Zeit/Lucy	Zeitraffer/Zeitlupe

Teil 3: Brückenmetapher

v4	v5
„Der Gesetzestext“	„Der erfahrene Richter“
Symbolisch-regelbasiert	Kognitiv-architektonisch
Iterativ determiniert	Energieoptimiert

Anhang B: METIS-Gesamtarchitektur (Integrationskontext)

ADJ v4+v5 agieren als METIS-Service für logische Entscheidungen:

Input → METIS → ADJ v4+v5 → METIS → Agent → HEIMDALL → User

Komponente	Rolle
METIS	Haupt-Orchestrator
ADJ v4	Epistemischer Prüfer
ADJ v5	Decision Support (Routing/Tempus)
HEIMDALL	Security-Gate vor User-Freigabe

Literaturverzeichnis

1. Popper, K. R. (1934). *Logik der Forschung*. Wien: Springer.
2. Kahneman, D. (2011). *Thinking, Fast and Slow*. New York: Farrar, Straus and Giroux.
3. Hofstadter, D. R. (1979). *Gödel, Escher, Bach: An Eternal Golden Braid*. New York: Basic Books.
4. Sio, U. N. & Ormerod, T. C. (2009). Does incubation enhance problem solving? A meta-analytic review. *Psychological Bulletin*, 135(1), 94–120.
5. Monaghan, P., Sio, U. N., & Ormerod, T. C. (2015). Constraints, theory and methodology in incubation research. (Forschungskontext für per-Complexity)
6. ADJ-Systemdokumentation v4/v5. Eigenentwicklung (2025–2026).
<https://github.com/Masterq83/ADJ-System>
7. Thorne, J. et al. (2018). FEVER: Fact Extraction and VERification. *NAACL*.
8. Manakul, P. et al. (2023). SelfCheckGPT. *EMNLP*.
9. Zheng, L. et al. (2023). Judging LLM-as-a-Judge. *NeurIPS Workshop*.
10. Lin, S. et al. (2022). TruthfulQA. *ACL*.

Erstellt: 2026-06-30 | Aktualisiert: 2026-07-05 | Preprint v6.1 | Lizenz: CC0 | Nicht peer-reviewed | EPI-Suite: 487/487 + H120 + Z100 + LIVE487 + FEVER500; Human30 vorbereitet.

Struktur orientiert am Preprint HEIMDALL–METIS Coherence Model (AGI Thermalistik, Juni 2026).